

Análise de atividades fraudulentas em cartões de crédito usando Aprendizagem de Máquina

Bruno Aguiar Carneiro Silva¹, Edson Coelho Rodrigues¹,
Ernesto D’Alva de Medeiros¹

Departamento de Computação
Universidade Federal do Ceará, Brazil

{bruno2, edson.coelho, ernestodalva} @alu.ufc.br

Abstract. Como trabalho final da disciplina de Aprendizagem de Máquina, do curso de Ciência da Computação, analisaremos nesse artigo o desempenho de três modelos de classificação de um conjunto de dados sobre fraudes em cartões de créditos, retirado do site Kaggle. Mediremos o desempenho em diferentes métricas, com a devida discussão dos resultados.

1. Introdução

A facilidade de compras com meios de pagamento online tornou ainda mais fáceis os pagamentos via cartão de crédito ao longo dos anos. A segurança dos métodos de pagamento online é o atributo mais valorizado em compras e atividades online por 91% dos entrevistados do Relatório de Identidade Digital e Fraude (SERASAEXPERIAN,2025). A pesquisa também aponta que 84% dos entrevistados dizem utilizar o cartão de crédito como meio preferido de pagamento online. Além disso, 51% afirmaram já terem sido vítimas de fraudes (o número era 42% em 2024).

Diante da preferência do consumidor pelo método de pagamento e o crescente número de incidência de fraudes percebidas pelos clientes, resolvemos analisar o desempenho de modelos de aprendizado de máquina para identificar fraudes na base de dados escolhida. Esse trabalho se divide da seguinte forma: A seção 2 apresenta o conjunto de dados utilizado. A seção 3 explica a metodologia do trabalho e da criação dos modelos. A seção 4 discute os resultados dos experimentos. Por fim, a seção 5 conclui o trabalho.

2. Fundamentação teórica

Essa seção descreve brevemente o problema e mostra com mais profundidade os dados usados.

2.1. Apresentação do Conjunto de dados escolhido

O dataset escolhido foi o Credit Card Fraud Detection Dataset 2023, facilmente encontrado no site Kaggle¹. Nosso dataset contém 568, 630 tuplas, em que cada uma representa uma operação de cartão de crédito realizado na Europa em 2023. Ao todo são 31 atributos, sendo 28 desses atributos dados anonimizados que representam atributos da transação (tempo, localização, etc). Os outros 3 atributos são o id da transação, o valor da transação e a classe da transação, onde 0 representa que a operação não é fraudulenta e 1 indica que aquela operação é fraudulenta.

¹<https://www.kaggle.com/datasets/nelgiriwithana/credit-card-fraud-detection-dataset-2023>

Atributo	Descrição
Id	Identificador da transação
V1-V28	Dados anonimizados que representam operações da transação(tempo,localização,etc)
Amount	Valor da transação
Class	Rótulo binário indicando se a transação é fraudulenta (1) ou não (0)

Tabela 1. Descrição dos atributos

A tabela 1 traz uma breve descrição de cada atributo. Todos esses atributos tratam de aspectos das transações de cartão de crédito e todos são representados por valores reais. Não temos como objetivo aqui destrinçar detalhes da relação de importância de cada atributo na resolução do problema.

2.2. Trabalhos relacionados

A necessidade de garantir segurança nas transações financeiras potencializou diversas pesquisas na área de aprendizagem de máquina, buscando prever e evitar as fraudes tão danosas para o mercado financeiro. Entre esses trabalhos, destacamos [Nazerke et al., 2025], [Awoyemi et al., 2017], [Alrasheedi, 2025], e [OLIVEIRA, 2025]. Desses, o trabalho de [Alrasheedi, 2025] utiliza o mesmo conjunto de dados usados neste trabalho, [Nelgiriyeewithana, 2023].

3. Metodologia

3.1. Algoritmos usados

O problema escolhido de detecção de fraude em operações de cartão de crédito é um clássico problema de classificação binária. Tendo isso em vista, escolhemos os modelos mais robustos entre aqueles vistos durante a disciplina de aprendizado de máquina. Para a criação destes usamos as implementações das bibliotecas Scikit-Learn e cuML do Python.

O primeiro escolhido foi a **Regressão Logística**. O motivo da escolha é simples: trata-se de um modelo simples e eficiente para o problema de classificação. Também foi utilizado o **Naive Bayes Gaussiano**, que foi selecionado por ser um classificador probabilístico simples e eficiente, especialmente indicado para atributos numéricos contínuos, assumindo distribuição normal das variáveis e independência condicional entre elas. Além deles usamos um modelo de **Support Vector Machine (SVM)**, por entendermos que se trata de um modelo mais robusto que os demais. Todos os modelos foram vistos durante a disciplina de Aprendizado de Máquina.

3.2. Treinamento dos modelos

O treinamento dos modelos constitui a etapa fundamental deste trabalho. Para garantir uma avaliação robusta da capacidade de generalização e um ajuste adequado de hiperparâmetros, adotamos a estratégia de Validação Cruzada Aninhada (*Nested K-Fold Cross Validation*), estruturada com cinco *folds* externos e cinco *folds* internos para cada um dos três modelos escolhidos.

Para cada ciclo externo, percorremos cinco ciclos internos realizando o *Grid Search*, com o objetivo de selecionar o melhor conjunto de hiperparâmetros para cada divisão de treinamento. Em seguida, realizamos o teste no fold da iteração atual do ciclo externo.

É importante ressaltar que, para os modelos de Regressão Logística e SVM, mais sensíveis à escala dos atributos, aplicamos a normalização Z-Score nos dados, baseados nos conjuntos de treino. Essa ação é necessária para evitar que atributos com magnitudes maiores dominem o cálculo de distâncias ou a otimização dos parâmetros, distorcendo o aprendizado e os resultados do experimento.

3.3. Métricas

Para consolidar os resultados e garantir a consistência da análise, calculamos a média e o desvio padrão das seguintes métricas de desempenho obtidas nos loops externos: Acurácia, Precisão, Revocação e F1-Score. Também apresentamos uma Matriz de Confusão média para sumarizar os acertos e erros globais dos classificadores. Nesta matriz resultante, cada célula corresponde à média aritmética das células equivalentes nas 5 matrizes de confusão geradas individualmente em cada iteração do loop externo.

Métrica	Descrição
Acurácia	Percentual de acertos gerais do modelo, considerando todos os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.
Precisão	Proporção de exemplos corretamente classificados como positivos em relação ao total de exemplos classificados como positivos.
Revocação	Proporção de exemplos positivos corretamente identificados em relação ao total de exemplos realmente positivos.
F1-score	Média harmônica entre precisão e revocação, usada quando há um balanço entre as duas métricas.
Matriz de confusão	Tabela que sumariza os acertos e erros de um classificador.

Tabela 2. Descrição das métricas usadas

4. Experimentos

4.1. Grid Search com Validação Cruzada

Os *loops* internos da validação cruzada aninhada são representados por uma seleção de hiperparâmetros conduzida via *Grid Search* acoplado a uma validação cruzada estratificada (*StratifiedKfold*), utilizando a acurácia como métrica de otimização. Para assegurar a integridade do processo experimental, o pré-processamento via *StandardScaler* (quando aplicável) e o classificador foram encapsulados sequencialmente em um objeto *Pipeline*. Essa arquitetura garante que os parâmetros de normalização sejam ajustados exclusivamente nos dados de treino de cada divisão interna, prevenindo o vazamento de dados (*data leakage*). Por fim, a avaliação de generalização no loop externo computou não apenas a acurácia, mas também o F1-score, precisão, revocação e a matriz de confusão para cada iteração

O conjunto de hiperparâmetros usados no *Grid Search* da Regressão Logística e do *SVM* estão presentes, respectivamente, nas tabelas 3 e 4.

Hiperparâmetro	Valores usados
eta0	[1e-2, 1e-3, 1e-4]
alpha	[1e-3, 1e-2, 1e-1, 1.0]

Tabela 3. Hiperparâmetros SGD

Hiperparâmetro	Valores usados
C	[0.1 ,1 , 10 , 100]
gamma	[1, 0.1, 0.01, 0.001]

Tabela 4. Hiperparâmetros SVM

4.2. Resultados obtidos usando os modelos descritos

Os dados apresentados a seguir, foram obtidos a partir do cálculo da média e desvio padrão das métricas (Tabela 2) obtidas nas cinco iterações externas da Validação Cruzada Aninhada.

Os resultados da Regressão Logística podem ser vistos na tabela 5a. O modelo apresentou um ótimo resultado em precisão, com total de 0,9823, o que significa uma baixa quantidade de falsos positivos, apresentando também uma revocação de 0,9393. Isso significa que o modelo consegue capturar boa parte dos resultados positivos, deixando de fora aproximadamente 0,06 deles.

Os resultados do modelo Naive Bayes Gaussiano estão presentes na tabela 5b. Diferentemente da Regressão Logística, o Naive Bayes Gaussiano apresentou uma diferença grande entre precisão e revocação, sendo esta métrica a menor obtida em todos os modelos. O modelo não consegue capturar cerca de 15% dos falsos negativos, o que, num cenário de combate a fraudes representa um resultado preocupante.

Essa performance se explica pela própria definição do algoritmo, que considera os atributos independentes entre si dada a classe. O modelo acaba por ignorar possíveis correlações entre localização, valor da transação e outras variáveis que podem estar correlacionadas.

Métrica	μ	σ	Métrica	μ	σ	Métrica	μ	σ
Acurácia	0.9612	0.0008	Acurácia	0.9163	0.0011	Acurácia	0.9999	0.0000
Revocação	0.9393	0.0030	Revocação	0.8487	0.0018	Revocação	1.0000	0.0000
Precisão	0.9823	0.0025	Precisão	0.9814	0.0007	Precisão	0.9998	0.0000
F1-score	0.9603	0.0009	F1-score	0.9102	0.0013	F1-score	0.9999	0.0000

(a) SGD

(b) Naive Bayes

(c) SVM

Tabela 5. Comparativo dos resultados finais entre os modelos.

Os resultados do SVM, sintetizados na tabela 5c, registram um comportamento inesperado com métricas anormalmente altas. Suspeitamos que isso tenha acontecido por conta do balanceamento perfeito das classes (50/50) no dataset escolhido. Além disso, pode ser que esse dataset possua classes com separabilidade muito alta. O SVM, com sua capacidade de criar fronteiras de decisão complexas, conseguiu separar as classes trivialmente. Isso sugere que os dados podem não possuir o ruído e a sobreposição de classes

típicos de fraudes reais, facilitando excessivamente a classificação. O trabalho de [Alrasheedi, 2025] que utilizou esse *dataset* também registrou dificuldades no desempenho do SVM.




Figura 1. Matrizes de confusão média para os três modelos comparados.

5. Conclusão

Este estudo avaliou o desempenho da Regressão Logística, Naive Bayes e SVM na detecção de fraudes em cartões de crédito. Os resultados apontaram a Regressão Logística como o modelo mais equilibrado e confiável para o problema. O Naive Bayes apresentou o pior desempenho, limitado pela suposição de independência entre atributos, enquanto o SVM exibiu métricas perfeitas atípicas, sugerindo características enviesadas no conjunto de dados utilizado, conforme também observado em trabalhos relacionados. Como trabalhos futuros, sugere-se uma investigação aprofundada das propriedades do *dataset*, como uma Análise de Componentes Principais (PCA) para determinar quais colunas estão tendo mais influência na detecção das fraudes.

Referências

- M. A. Alrasheedi. Enhancing fraud detection in credit card transactions: A comparative study of machine learning models. *Computational Economics*, 2025. doi: 10.1007/s10614-025-11071-3. URL <https://doi.org/10.1007/s10614-025-11071-3>.
- J. O. Awoyemi, A. O. Adetunmbi, and S. A. Oluwadare. Credit card fraud detection using machine learning techniques: A comparative analysis. *IEEE*, 2017.
- B. Nazerke, J. E. Dietz, S. Gnatyuk, M. Turdalyuly, E. T. Matson, and K. Baisholanova. A systematic review of machine learning in credit card fraud detection under original class imbalance. *Computers*, 14:437, 2025.
- N. Nelgiriyeewithana. Credit card fraud detection dataset 2023. kaggle. Disponível em <https://www.kaggle.com/datasets/nelgiriyeewithana/credit-card-fraud-detection-dataset-2023>, 2023.
- V. D. OLIVEIRA. Métodos de machine learning na detecção de fraude em cartão de crédito: um estudo comparado. *Universidade Federal de São Paulo*, 2025.